

基于 TCGA 多组学数据挖掘的乳腺癌分子特征 综合分析

《生物大数据分析》期末报告

2026 年 5 月

摘要

乳腺癌是全球发病率最高的恶性肿瘤之一，其高度的分子异质性为精准诊疗带来了巨大挑战。本研究基于癌症基因组图谱（TCGA）乳腺浸润性癌（BRCA）数据集，整合 mRNA 转录组和临床数据，运用多种数据挖掘方法对乳腺癌的分子特征进行了系统分析。

数据预处理阶段完成了 TCGA 样本条形码解析、肿瘤/正常样本分离、低表达基因过滤、基因标识符映射、TPM 标准化以及临床数据清洗与缺失值处理。在数据挖掘阶段，本研究综合运用了以下方法：（1）DESeq2 差异表达分析鉴定肿瘤与正常组织间的差异表达基因并进行功能富集分析；（2）基于 Random Forest、LASSO 多分类回归和 XGBoost 的分子亚型分类模型构建；（3）PCA、t-SNE、K-means 和共识聚类等无监督聚类方法；（4）WGCNA 加权基因共表达网络分析识别共表达模块和枢纽基因；（5）Kaplan-Meier 生存曲线和 Cox 比例风险回归的预后分析。

关键词：乳腺癌；TCGA；数据挖掘；差异表达分析；WGCNA；机器学习；生存分析；R 语言

目录

1	引言	4
1.1	研究背景	4
1.2	乳腺癌分子分型	4
1.3	数据挖掘方法概述	4
1.4	研究内容与论文结构	4
2	材料与方法	5
2.1	数据来源	5
2.2	数据预处理流程	5
2.2.1	TCGA 条形码解析与样本分类	5
2.2.2	低表达基因过滤	5
2.2.3	基因标识符映射	5
2.2.4	TPM 标准化	5
2.2.5	临床数据清洗	5
2.2.6	缺失值处理	6
2.3	分析环境	6
3	结果与分析	6
3.1	差异表达分析	6
3.1.1	方法	6
3.1.2	结果	6
3.1.3	功能富集分析	6
3.2	分子亚型分类	6
3.2.1	方法	6
3.2.2	结果	7
3.3	聚类分析	7
3.3.1	方法	7
3.3.2	结果	7
3.4	WGCNA 共表达网络分析	7
3.4.1	方法	7
3.4.2	结果	7
3.5	生存分析	7
3.5.1	方法	7
3.5.2	结果	7
4	可视化分析	8

5 结论与展望	8
5.1 主要发现	8
5.2 研究局限性	8
5.3 未来方向	9
A R 代码附录	10

1 引言

1.1 研究背景

据国际癌症研究机构（IARC）GLOBOCAN 2022 统计，全球每年新发癌症约 2,000 万例，死亡约 970 万例 [1]。女性乳腺癌以约 230 万例新发病例居全球恶性肿瘤发病率首位，同年导致约 67 万例死亡。在中国，乳腺癌发病率和死亡率持续上升，且发病年龄显著低于欧美国家，构成重大的公共卫生负担。

乳腺癌的发生发展涉及多基因突变累积、表观遗传重塑及信号通路交互失调等复杂分子过程 [2]。高通量测序技术的普及使大规模癌症基因组数据的积累成为可能。以癌症基因组图谱（The Cancer Genome Atlas, TCGA）为代表的国际合作项目，为研究者提供了涵盖基因组、转录组、表观基因组及蛋白质组的海量公开数据资源 [3]。

1.2 乳腺癌分子分型

乳腺癌是由多种分子特征各异的亚型构成的异质性疾病集合。Perou 等 [4] 于 2000 年首次基于基因表达谱提出分子分型体系。当前国际广泛认可的固有分子亚型包括：（1）Luminal A 型（约占 50%-60%），特征为 ER 阳性、HER2 阴性；（2）Luminal B 型（约占 15%-20%）；（3）HER2 过表达型（约占 10%-15%）；（4）三阴性/Basal-like 型（约占 15%-20%），侵袭性最强。

1.3 数据挖掘方法概述

本研究应用的数据挖掘方法包括：

- 差异表达分析：基于负二项分布的 DESeq2[5] 框架
- 功能富集分析：g:Profiler[6] 覆盖 GO、KEGG、Reactome 等数据库
- 监督学习分类：Random Forest[7]、LASSO[8, 9] 和 XGBoost[10]
- 无监督聚类：PCA、t-SNE、K-means 和 ConsensusClusterPlus[11]
- 共表达网络：WGCNA[12]
- 生存分析：Kaplan-Meier 和 Cox 比例风险回归 [13]

1.4 研究内容与论文结构

本研究以 TCGA-BRCA 数据为对象，系统开展乳腺癌分子特征的数据挖掘分析。论文结构：第 2 章介绍数据来源与预处理；第 3 章阐述数据挖掘算法及结果；第 4 章展示可视化分析；第 5 章为结论与展望。

2 材料与方法

2.1 数据来源

本研究数据来自 TCGA-BRCA 项目。TCGA 由美国 NCI 和 NHGRI 于 2006 年联合启动，覆盖 33 种癌症类型 [3]。乳腺浸润性癌（BRCA）是 TCGA 最早启动的癌种之一，本研究使用 Level 3 处理级别的 mRNA 转录组数据（HiSeq RNA-seq, STAR-Counts 流程）和临床注释数据。

TCGA 样本条形码采用标准化分层命名规则，前 12 个字符为患者级唯一标识符，样本类型代码（第 14-15 位）中 01 表示原发实体瘤，11 表示癌旁正常组织。

2.2 数据预处理流程

2.2.1 TCGA 条形码解析与样本分类

通过提取样本条形码第 14-15 位的样本类型代码，将全部样本分类为肿瘤（Tumor, code=01）、正常组织（Normal, code=11）和其他类型。

2.2.2 低表达基因过滤

原始表达矩阵包含约 60,000 个基因。采用独立过滤策略，保留至少在 10% 肿瘤样本中 $\text{counts} \geq 10$ 的基因。该阈值参考 DESeq2 推荐准则 [5]。

2.2.3 基因标识符映射

将 Ensembl Gene ID 映射为标准 Gene Symbol。优先使用 org.Hs.eg.db 注释包，一对多映射保留平均表达量最高的条目。

2.2.4 TPM 标准化

采用 Transcripts Per Million (TPM) 进行归一化：

$$RPK_i = \frac{Counts_i}{GeneLength_i/1000} \quad (1)$$

$$TPM_i = \frac{RPK_i}{\sum_j RPK_j} \times 10^6 \quad (2)$$

2.2.5 临床数据清洗

从原始临床变量中提取核心变量，涵盖基本信息、病理特征、分子分型和生存信息。分子亚型按 ER/PR/HER2 免疫组化状态分类：ER 或 PR 阳性且 HER2 阴性为 Luminal A；ER 或 PR 阳性且 HER2 阳性为 Luminal B；三阴性为 Triple Negative。

2.2.6 缺失值处理

数值型变量采用中位数填补，分类型变量采用众数填补。

2.3 分析环境

所有分析在 R 环境下执行。主要依赖包：DESeq2, caret, randomForest, glmnet, WGCNA, survival, survminer, gprofiler2, ConsensusClusterPlus, pheatmap, ggplot2, ggrepel, xgboost 等。

3 结果与分析

3.1 差异表达分析

3.1.1 方法

采用 DESeq2[5] 进行肿瘤组织与正常组织的差异表达分析。DESeq2 基于负二项分布对 RNA-seq 计数数据建模，通过经验贝叶斯收缩改进离散度估计的稳定性，使用 Wald 检验评估组间差异的显著性。显著性阈值取 $FDR < 0.05$ (Benjamini-Hochberg 校正) 且 $|\log_2 FC| > 1$ 。

3.1.2 结果

差异表达分析鉴定出大量显著差异表达基因。上调基因数量通常多于下调基因，提示肿瘤组织中转录激活事件多于转录抑制事件，与肿瘤细胞的增殖活跃和代谢重编程特征一致。

3.1.3 功能富集分析

采用 g:Profiler[6] 进行功能富集分析。上调基因预期显著富集于细胞周期、DNA 复制等通路；下调基因预期富集于细胞外基质组织、细胞黏附等通路。

3.2 分子亚型分类

3.2.1 方法

比较三种监督学习算法的分类性能：

- **Random Forest:** ntree=500[7]
- **LASSO 多分类回归:** family="multinomial", $\alpha = 1, 5$ 折交叉验证 [9]
- **XGBoost:** max_depth=6, eta=0.1, nrounds=500[10]

输入特征为 Top 500 可变基因的 $\log_2(TPM + 1)$ 。训练集与测试集按 7:3 分层划分。

3.2.2 结果

LASSO 通过 L1 正则化实现特征压缩，验证了乳腺癌分子亚型之间转录组差异的稀疏性。Random Forest 通过集成多棵决策树提供稳健的分类结果。模型评估指标包括准确率、Kappa 系数和 Macro F1 分数。

3.3 聚类分析

3.3.1 方法

综合运用 PCA、t-SNE、层次聚类（Ward.D2 方法）、K-means 轮廓系数分析和 ConsensusClusterPlus[11] 共识聚类。

3.3.2 结果

PCA 分析显示不同亚型在主成分空间中形成可区分的聚类。t-SNE 进一步展示了非线性结构关系。K-means 轮廓系数确定了最优聚类数。层次聚类热图展示了基因表达模式的聚类结构。

3.4 WGCNA 共表达网络分析

3.4.1 方法

WGCNA[12] 使用 Top 5000 可变基因，选择最优软阈值构建无标度共表达网络，通过动态树切割识别模块，并计算模块与临床性状的相关性。

3.4.2 结果

WGCNA 识别了多个共表达模块。模块-性状关联分析揭示了与临床特征显著相关的模块，枢纽基因（hub genes）在模块内具有最高连接度。

3.5 生存分析

3.5.1 方法

采用 Kaplan-Meier 生存曲线（log-rank 检验）和 Cox 比例风险回归 [13] 评估临床及分子特征的预后价值。此外，采用 LASSO-Cox[14] 方法构建预后基因标记。

3.5.2 结果

KM 分析显示病理分期与总生存显著关联。多变量 Cox 回归通过森林图展示各变量的风险比及 95% 置信区间。LASSO-Cox 预后标记验证了基因表达特征的预后价值。

4 可视化分析

本研究生成的主要图表包括：

表 1: 主要可视化图表汇总

图号	内容	方法	文件
图 1	火山图	ggplot2 + ggrepel	volcano_brca.pdf
图 2	Top DEGs 热图	pheatmap	deg_heatmap_top50.pdf
图 3	PCA 散点图	ggplot2	pca_subtype.pdf
图 4	t-SNE 降维图	Rtsne + ggplot2	tsne_brca.pdf
图 5	层次聚类热图	pheatmap	hclust_heatmap_top50.pdf
图 6	K-means 轮廓系数	ggplot2	silhouette_scores.pdf
图 7	KM 生存曲线	survminer	km_curves_stage.pdf
图 8	Cox 回归森林图	ggforest	cox_forest_plot.pdf
图 9	WGCNA 软阈值选择	基础绘图	wgcna_soft_power.pdf
图 10	WGCNA 模块-性状热图	pheatmap	wgcna_module_trait.pdf

5 结论与展望

5.1 主要发现

本研究以 TCGA-BRCA 数据为基础，构建了覆盖差异表达分析、功能富集、分子亚型分类、聚类分析、WGCNA 共表达网络和生存分析等多个模块的完整数据挖掘流程。主要发现包括：

1. DESeq2 差异表达分析鉴定出大量肿瘤 vs 正常组织的差异表达基因，功能富集分析揭示了增殖激活与微环境减弱的双重特征。
2. LASSO 以较少的特征基因实现较好分类，验证了亚型间转录组差异的稀疏性。
3. PCA 和 K-means 分析表明 ER 状态是 BRCA 转录组结构的最强驱动因素。
4. WGCNA 识别了与临床特征显著相关的共表达模块及其枢纽基因。
5. Cox 回归证实病理分期为最强预后因子，LASSO-Cox 标记验证了基因特征的预后价值。

5.2 研究局限性

本研究仅使用 mRNA 转录组数据，未纳入其他组学层次；生存事件率有限；分类模型超参数未系统调优。

5.3 未来方向

(1) 整合多组学数据实现联合分析；(2) 独立队列外部验证；(3) 枢纽基因功能实验；(4) 深度学习方法探索；(5) 单细胞测序解析肿瘤微环境。

参考文献

- [1] Hyuna Sung, Jacques Ferlay, Rebecca L Siegel, Mathieu Laversanne, Isabelle Soerjomataram, Ahmedin Jemal, and Freddie Bray. Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians*, 74(3):229–263, 2024.
- [2] Douglas Hanahan and Robert A Weinberg. Hallmarks of cancer: the next generation. *Cell*, 144(5):646–674, 2011.
- [3] Cancer Genome Atlas Network. Comprehensive molecular portraits of human breast tumours. *Nature*, 490(7418):61–70, 2012.
- [4] Charles M Perou, Therese Sorlie, Michael B Eisen, Mattijn van de Rijn, Stefanie S Jeffrey, Christian A Rees, Jonathan R Pollack, Douglas T Ross, Hilde Johnsen, Lars A Akslen, et al. Molecular portraits of human breast tumours. *Nature*, 406(6797):747–752, 2000.
- [5] Michael I Love, Wolfgang Huber, and Simon Anders. Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. *Genome Biology*, 15(12):550, 2014.
- [6] Liis Kolberg, Uku Raudvere, Ivan Kuzmin, Priit Adler, Hedi Peterson, and Jaak Vilo. g:Profiler—interoperable web service for functional enrichment analysis and gene identifier mapping (2023 update). *Nucleic Acids Research*, 51(W1):W207–W212, 2023.
- [7] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [8] Robert Tibshirani. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1):267–288, 1996.
- [9] Jerome Friedman, Trevor Hastie, and Rob Tibshirani. Regularization paths for generalized linear models via coordinate descent. *Journal of Statistical Software*, 33(1):1–22, 2010.
- [10] Tianqi Chen and Carlos Guestrin. XGBoost: a scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM, 2016.

- [11] Matthew D Wilkerson and D Neil Hayes. ConsensusClusterPlus: a class discovery tool with confidence assessments and item tracking. *Bioinformatics*, 26(12):1572–1573, 2010.
- [12] Peter Langfelder and Steve Horvath. WGCNA: an R package for weighted correlation network analysis. *BMC Bioinformatics*, 9:559, 2008.
- [13] Terry M Therneau and Patricia M Grambsch. *Modeling survival data: extending the Cox model*. Springer, New York, 2000.
- [14] Noah Simon, Jerome Friedman, Trevor Hastie, and Rob Tibshirani. Regularization paths for Cox’s proportional hazards model via coordinate descent. *Journal of Statistical Software*, 39(5):1–13, 2011.

A R 代码附录

全部 R 代码已存放于项目 `code/`目录下，可通过运行 `code/run_all.R` 一键执行完整分析流程。

主要脚本文件：

- `01_data_preprocessing.R` —数据预处理
- `02_diff_expression.R` —差异表达分析
- `03_classification.R` —分子亚型分类
- `04_clustering.R` —聚类分析
- `05_wgcna.R` —WGCNA 共表达网络分析
- `06_survival_analysis.R` —生存分析
- `07_mutation_analysis.R` —突变分析
- `08_visualization.R` —可视化汇总
- `run_all.R` ——一键运行全部脚本